

บทที่ 3 การวิเคราะห์ข้อมูลด้วยสถิติพรรณนา

เนื้อหา

- 3.1 ความหมายและความสำคัญของสถิติพรรณนา
- 3.3 การแจกแจงความถี่ (Frequency Distribution)
- 3.2 การวัดแนวโน้มเข้าสู่ศูนย์กลาง (Measures of Central Tendency)
- 3.4 การวัดการกระจายของข้อมูล (Measures of Dispersion)
- 3.5 การวิเคราะห์ลักษณะการแจกแจงของข้อมูล
- 3.6 การนำเสนอข้อมูลเบื้องต้น
- 3.7 การประยุกต์ใช้สถิติพรรณนาในการวิเคราะห์ข้อมูล
- 3.8 ข้อจำกัดของการใช้สถิติพรรณนา

วัตถุประสงค์การเรียนรู้

- 1) อธิบายความหมายของสถิติพรรณนาได้อย่างถูกต้อง และเข้าใจบทบาทและสามารถระบุวัตถุประสงค์ เทคนิค และการประยุกต์ใช้ที่เหมาะสมของสถิติทั้งสองประเภทในบริบทที่แตกต่างกัน
- 2) อธิบายแนวคิดพื้นฐานเกี่ยวกับค่ากลางในทางสถิติและความสำคัญของการวัดค่ากลางในการวิเคราะห์ข้อมูลทางสถิติ รวมถึงเข้าใจถึงประโยชน์และข้อจำกัดของการวิเคราะห์ข้อมูลโดยใช้ค่ากลางเพียงอย่างเดียว
- 3) คำนวณของค่าเฉลี่ยเลขคณิต ค่าเฉลี่ยถ่วงน้ำหนัก ค่าเฉลี่ยเรขาคณิต มัธยฐาน และฐานนิยม และสามารถแปลความหมายของผลลัพธ์ที่ได้จากการคำนวณในบริบทของปัญหาที่กำลังศึกษา
- 4) อธิบายและประยุกต์ใช้มาตรวัดการกระจายที่สำคัญ ได้แก่ ความแปรปรวนและส่วนเบี่ยงเบนมาตรฐาน ผู้เรียนจะต้องเข้าใจแนวคิดพื้นฐานเกี่ยวกับการวัดการกระจายของข้อมูล สามารถอธิบายความหมายและความสำคัญของความแปรปรวนและส่วนเบี่ยงเบนมาตรฐานในการวิเคราะห์ข้อมูล

3.1 ความหมายและความสำคัญของสถิติพรรณนา

สถิติพรรณนา เป็นการวิเคราะห์ข้อมูลเบื้องต้น เพื่อให้ทราบลักษณะโดยรวมและภาพกว้างๆ ของข้อมูล ที่ทำการเก็บรวบรวมมา เพื่อตรวจสอบว่าข้อมูลมีค่ากลาง ค่าการกระจายตัว รวมถึงค่าผิดปกติ (outlier) หรือไม่ ซึ่งมีวิธีการและเทคนิคต่างๆ แตกต่างกันตามวัตถุประสงค์ ได้แก่ การแจกแจงความถี่ การวัดแนวโน้มเข้าสู่ศูนย์กลาง และการวัดการกระจายของข้อมูล

3.2 การแจกแจงความถี่ (Frequency Distribution)

การแจกแจงความถี่ (Frequency Distribution) เป็นวิธีการจำแนกข้อมูลที่ซ้ำกันแล้วทำการนับความถี่ (frequency) เพื่อให้ทราบว่าข้อมูลส่วนใหญ่อยู่มีค่าเป็นเท่าไร การแจกแจงความถี่ช่วยให้มองเห็นลักษณะการกระจายของข้อมูล ทำให้ง่ายต่อการวิเคราะห์และตีความ

3.2.1 การแจกแจงความถี่ด้วยแผนภาพกึ่งและใบไม้ (Stem and Leaf)

ตัวอย่าง ยอดขายเครื่องดื่มสมุนไพรร 10 วันเป็นดังนี้

120	95	80	98	94
112	100	112	112	140

จงสร้างแผนภาพกึ่งและใบไม้

8 |
9 |
10 |
11 |
12 |
13 |
14 |

3.2.2 การแจกแจงความถี่ด้วยตาราง (Frequency Table)

1) ตารางแจกแจงความถี่ กรณีข้อมูลไม่มีการจัดหมวดหมู่

ตัวอย่าง: ข้อมูลการสูบบุหรี่ของพนักงานบริษัทแห่งหนึ่ง

ตารางแจกแจงความถี่

id	age	sex	smoker	income (thousand)
1	19	female	yes	70
2	18	male	no	80
3	28	male	no	78
4	33	male	no	89
5	32	male	no	45
6	31	female	no	60
7	46	female	yes	100
8	37	female	yes	55
9	37	male	no	46
10	60	female	no	73
11	25	male	no	89
12	62	female	yes	86
13	23	male	no	75
14	56	female	no	99
15	27	male	yes	110
16	19	male	no	102
17	52	female	no	98
18	23	male	no	75
19	56	male	no	65
20	30	male	yes	98

เพศ	รอยขีด (Tally)	ความถี่ (Frequency)
ชาย		
หญิง		
รวม		

smoker	รอยขีด (Tally)	ความถี่ (Frequency)
Yes		
No		
รวม		

2) ตารางแจกแจงความถี่ กรณีข้อมูลมีการจัดหมวดหมู่

ตัวอย่าง: ปริมาณขายน้ำผลไม้ (ขวด) ในแต่ละวัน จำนวน 50 วัน ($n = 50$) จงสร้างตารางแจกแจงความถี่

65	61	47	75	84	87	65	59	63	86
68	63	43	76	90	79	50	89	68	57
95	55	69	48	76	60	77	49	92	83
61	78	53	52	77	58	93	85	70	62
80	74	69	40	62	84	64	36	48	72

ปริมาณขาย	ขอบเขตชั้น	จุดกึ่งกลาง	รอยขีด	ความถี่
34 – 42	33.5 – 42.5	38		2
43 – 51	42.5 – 51.5	47		6
52 – 60	51.5 – 60.5	56		7
61 – 69	60.5 – 69.5	65		13
70 – 78	69.5 – 78.8	74		9
79 – 87	78.5 – 87.5	83		8
88 – 96	87.5 – 96.5	92		5
รวม				50

ขั้นตอน 1: กำหนดจำนวนอันตรภาคชั้น $k = 1 + 3.3 \log n$ เมื่อ n แทนจำนวนข้อมูล

ขั้นตอน 2: หาพิสัย (range) โดย $R = X_{\max} - X_{\min}$

ขั้นตอน 3: คำนวณความกว้างของชั้น โดย $I = \frac{R}{k}$

ขั้นตอน 4: คำนวณขีดจำกัดล่าง (lower class limit) และขีดจำกัดบน (upper class limit) ของชั้นแรก

$$\text{ขีดจำกัดล่าง (lower class limit)} = X_{\min} - \frac{(k * I) - R}{2}$$

$$\text{ขีดจำกัดบน (upper class limit)} = (\text{ขีดจำกัดล่าง} + I) - 1$$

ขั้นตอน 5: คำนวณขอบเขตบนของแต่ละชั้น

$$\text{ขอบเขตล่าง} = \frac{\text{ขีดจำกัดล่างของชั้น} + \text{ขีดจำกัดบนของชั้นต่ำกว่า}}{2}$$

$$\text{ขอบเขตบน} = \frac{\text{ขีดจำกัดบนของชั้น} + \text{ขีดจำกัดล่างของชั้นสูงกว่า}}{2}$$

ขั้นตอน 6: คำนวณจุดกึ่งกลาง

$$\text{จุดกึ่งกลาง} = \frac{\text{ขีดจำกัดล่าง} - \text{ขีดจำกัดบน}}{2}$$

3.3 การวัดแนวโน้มเข้าสู่ศูนย์กลาง (Measures of Central Tendency)

3.3.1 พารามิเตอร์ระหว่างประชากรและตัวอย่าง

การศึกษาทางสถิติและเศรษฐศาสตร์มักสนใจการวิเคราะห์คุณลักษณะของ “ประชากร (population)” เช่น รายได้ของคนทั้งประเทศ หรือการบริโภคของครัวเรือนทั้งประเทศ อย่างไรก็ตาม ในทางปฏิบัติ การเก็บข้อมูลจากทั้งประชากรมักทำได้ยากหรือใช้ทรัพยากรมากเกินไป ดังนั้น เราจึงเลือกเก็บข้อมูลจาก “ตัวอย่าง (sample)” เพื่อเป็นตัวแทนประชากร และทำการประมาณค่า (estimate) พารามิเตอร์ของประชากร

พารามิเตอร์ของประชากร คือ ค่าที่บ่งบอกลักษณะของประชากรทั้งหมด ซึ่งในเชิงทฤษฎีมักไม่ทราบค่าแน่ชัด ตัวอย่างพารามิเตอร์และสัญลักษณ์ ได้แก่

สัญลักษณ์ที่ใช้แทนพารามิเตอร์ระหว่างประชากรและตัวอย่าง

พารามิเตอร์	ประชากร	ตัวอย่าง
ค่าเฉลี่ย	μ	$\bar{X}$
ความแปรปรวน	σ^2	S^2
ส่วนเบี่ยงมาตรฐาน	σ	$s.d.$

ตัวอย่าง: นักเศรษฐศาสตร์ต้องการศึกษา ค่าเฉลี่ยผลผลิตข้าว (กิโลกรัมต่อไร่) ของเกษตรกรทั่วประเทศไทย ซึ่งเกษตรกรทั่วประเทศถือเป็นประชากร (population) ในการศึกษา เนื่องจากการเก็บข้อมูลผลผลิตจากเกษตรกรทุกคนทั่วประเทศเป็นไปได้ยาก นักเศรษฐศาสตร์จึงสุ่มตัวอย่างเกษตรกรจำนวน 500 คน จากทุกภูมิภาคของประเทศ แล้วคำนวณค่าเฉลี่ยผลผลิตจากกลุ่มตัวอย่างนี้

3.3.2 ค่าเฉลี่ย (Mean)

ค่าเฉลี่ย (Mean) คือ ค่าหนึ่งที่แสดงถึงจุดกึ่งกลางของชุดข้อมูลหรือแสดงค่ากลางที่ข้อมูลส่วนใหญ่ใกล้เคียงหรือมีการกระจายตัวรอบๆ ซึ่งทำหน้าที่เป็นตัวชี้วัดแนวโน้มเข้าสู่ศูนย์กลาง (measure of central tendency) ที่นิยมใช้มากที่สุดในทางสถิติและเศรษฐศาสตร์ เพราะช่วยสรุปข้อมูลจำนวนมากให้เหลือเพียงค่าตัวเลขเดียวที่แทนค่ากลางของข้อมูลนั้น ตัวอย่างเช่น ค่าเฉลี่ยรายได้ของครัวเรือน หรือค่าเฉลี่ยอัตราการว่างงาน

ค่าเฉลี่ยสามารถคำนวณได้หลายวิธี เช่น ค่าเฉลี่ยเลขคณิต (Arithmetic Mean), ค่าเฉลี่ยถ่วงน้ำหนัก (Weighted mean), ค่าเฉลี่ยเรขาคณิต (Geometric Mean), หรือค่าเฉลี่ยฮาร์โมนิก (Harmonic Mean) ในเอกสารนี้ จะอธิบายเฉพาะค่าเฉลี่ยเลขคณิต (Arithmetic Mean), ค่าเฉลี่ยถ่วงน้ำหนัก (Weighted mean)

ค่าเฉลี่ย	กรณีไม่ใช้ความถี่คำนวณ	กรณีใช้ความถี่คำนวณ
ประชากร	$\mu = \frac{\sum_{i=1}^N X_i}{N}$	$\mu = \frac{\sum_{i=1}^R f_i X_i}{\sum_{i=1}^R f_i}$
ตัวอย่าง	$\bar{X} = \frac{\sum_{i=1}^n X_i}{n}$	$\bar{X} = \frac{\sum_{i=1}^k f_i X_i}{\sum_{i=1}^k f_i}$

1) ค่าเฉลี่ยเลขคณิต (Arithmetic Mean)

ตัวอย่าง: หนังสือหมวดวิชาสถิติเศรษฐศาสตร์ 5 เล่ม มีราคาต่อชิ้นเท่ากับ 120, 200, 95, 150, 180 จงหา
ราคาเฉลี่ยของหนังสือ

2) ค่าเฉลี่ยถ่วงน้ำหนัก (Weighted mean)

ค่าเฉลี่ยถ่วงน้ำหนัก (Weighted Mean) เป็นการคำนวณค่าเฉลี่ยที่ให้น้ำหนักหรือความสำคัญ (weight) กับข้อมูลแต่ละค่าไม่เท่ากัน มักใช้เมื่อข้อมูลแต่ละค่ามีความสำคัญหรือความถี่แตกต่างกัน ซึ่งมีความแตกต่างจาก ค่าเฉลี่ยเลขคณิต (Arithmetic Mean) ที่สมมติให้ทุกค่าข้อมูลมีความสำคัญเท่าๆ กัน

ค่าเฉลี่ยถ่วงน้ำหนักที่พบบ่อยในเศรษฐศาสตร์ เช่น การคำนวณดัชนีราคาผู้บริโภค (CPI) ที่สินค้าต่างชนิดมีน้ำหนักในตะกร้าสินค้าต่างกัน การคำนวณเส้นค่าเฉลี่ยย้อนหลังของราคาหุ้น เป็นต้น

$$\bar{X} = \frac{\sum_{i=1}^R w_i X_i}{\sum_{i=1}^R w_i}$$

ตัวอย่าง: สมมติว่าต้องการคำนวณราคาเฉลี่ยของสินค้า 3 ชนิดในตะกร้าสินค้า โดยให้ราคาต่อหน่วยและน้ำหนักความสำคัญ (เช่น สัดส่วนการใช้จ่าย) ดังนี้

สินค้า	ราคา (บาท)	น้ำหนัก (%)
ข้าว	30	50
ไข่	4	30
น้ำปลา	10	20

3.3.3 มัธยฐาน (Median)

มัธยฐาน (Median) เป็นสถิติที่ใช้บอก ค่ากลาง ของข้อมูล เมื่อข้อมูลทั้งหมดถูกจัดเรียงจากน้อยไปมาก (ascending order) หรือจากมากไปน้อย (descending order) มัธยฐานจึงเป็นตัวชี้วัดแนวโน้มเข้าสู่ศูนย์กลาง (measure of central tendency) ที่นิยมใช้ โดยเฉพาะในกรณีที่ข้อมูลมี ค่าผิดปกติ (outlier) หรือ ข้อมูลกระจายไม่สมมาตร (skewed distribution) เพราะมัธยฐานไม่ได้รับผลกระทบจากค่าที่สุดโตรงเหล่านี้ เหมือนค่าเฉลี่ยเลขคณิต

มัธยฐานมักใช้เป็นตัวชี้วัดหลักในการวิเคราะห์ข้อมูลที่มีความเบ้ (skewed) หรือมีค่าผิดปกติ เนื่องจากสามารถสะท้อนค่ากลางที่แท้จริงได้ดีกว่าค่าเฉลี่ยเลขคณิต ตัวอย่างเช่น การกระจายรายได้ หรือ ความเหลื่อมล้ำทางเศรษฐกิจ ฯลฯ มักใช้มัธยฐานเป็นตัวชี้วัดหลักสำหรับในกรณีของข้อมูลที่มีผู้มีรายได้สูงมากเพียงไม่กี่คน

ข้อมูล	จำนวนเป็นเลขคี่	จำนวนเป็นเลขคู่
ไม่มีการจัดหมวดหมู่	$Me = \frac{N+1}{2}$	$Me = \frac{N}{2} \text{ vs. } \frac{N+1}{2}$ แล้วนำมาเฉลี่ย
มีการจัดหมวดหมู่	$Me = L_i + \frac{\left[\left(\frac{N}{2}\right) - F_L\right] I}{f}$	

ตัวอย่าง: จากข้อมูลยอดขายสินค้า A และสินค้า B จงหา มัธยฐานของชุดข้อมูลนี้

- สินค้า A เท่ากับ 84, 96, 80, 78, 99
- สินค้า B เท่ากับ 66, 68, 60, 65, 58, 62

3.3.4 ฐานนิยม (Mode)

ฐานนิยม (Mode) คือ ค่าของข้อมูลที่เกิดขึ้นบ่อยหรือมีความถี่มากที่สุดในชุดข้อมูลนั้นๆ โดยฐานนิยมเป็นหนึ่งในตัวชี้วัดแนวโน้มเข้าสู่ศูนย์กลาง (measure of central tendency) เช่นเดียวกับค่าเฉลี่ยและมัธยฐาน แต่มีลักษณะเด่น คือ สามารถใช้กับข้อมูลได้หลากหลายประเภท ทั้งข้อมูลเชิงคุณภาพ (qualitative) และเชิงปริมาณ (quantitative) ในขณะที่ค่าเฉลี่ยและมัธยฐานข้อมูลเชิงปริมาณและข้อมูลคุณภาพในระดับมาตรวัดแบบเรียงลำดับ (ordinal scale) ขึ้นไปเท่านั้น

ในงานเศรษฐศาสตร์ ฐานนิยมมักใช้กับข้อมูลจำแนกประเภท (categorical data) หรือข้อมูลจำนวนเต็มที่มีการนับความถี่ เช่น อาชีพของกลุ่มตัวอย่าง ระดับการศึกษาของกลุ่มตัวอย่าง เป็นต้น

ข้อมูล	ฐานนิยม
กรณีไม่จัดหมวดหมู่ข้อมูล	ค่าที่ซ้ำกันมากที่สุด
กรณีจัดหมวดหมู่ข้อมูล	$Mode = L_l + \left(\frac{\Delta_1}{\Delta_1 + \Delta_2} \right) I$ เมื่อ $\Delta_1 = f - f_L$ และ $\Delta_2 = f - f_H$

ตัวอย่าง: จงหาฐานนิยมจากข้อมูล ดังต่อไปนี้

- 5, 12, 9, 6, 7, 11, 18, 4, 10
- 5, 2, 5, 6, 9, 10, 5, 6, 2, 5
- 5, 2, 5, 6, 2, 10, 5, 10, 12, 2

ตัวอย่าง: จงหาฐานนิยมของประเภทที่อยู่อาศัยของครัวเรือนในเขตเมืองหนึ่ง ดังนี้

{บ้านเดี่ยว, ทาวน์เฮ้าส์, คอนโด, บ้านเดี่ยว, ทาวน์เฮ้าส์, บ้านเดี่ยว, บ้านเดี่ยว, คอนโด, บ้านเดี่ยว}

3.4 การวัดการกระจายของข้อมูล (Measures of Dispersion)

3.4.1 พิสัย (Range)

พิสัย (Range) คือ ผลต่างระหว่างค่าสูงสุดและค่าต่ำสุด $R = X_{\max} - X_{\min}$

3.4.2 ควอไทล์ (Quartiles)

ควอไทล์ (Quartiles) คือ การเรียงข้อมูลจากน้อยไปมาก และหาว่ามีชุดข้อมูลที่ต่ำกว่า r ส่วนจำนวนเท่าใด มักใช้สัญลักษณ์แทนด้วย Q_r

ไม่มีการจัดหมวดหมู่	มีการจัดหมวดหมู่
$Q_r = \frac{r(N+1)}{4}$	$Q_r = L_1 + \frac{\left(\frac{rN}{4} - F_L\right)I}{f_1}$ เมื่อ F_L แทนความถี่สะสมชั้นที่ต่ำกว่า

ตัวอย่าง: จากข้อมูล 5, 12, 9, 6, 7, 11, 18 จงหาควอไทล์ที่ 1, 2 และ 3

$$Q_r = \frac{r(N+1)}{4}$$

ขั้นตอน 1: เรียงข้อมูลจากน้อยไปมาก

ขั้นตอน 2: คำนวณควอไทล์ที่ 1

3.4.3 ความแปรปรวน (Variance)

ความแปรปรวน คำนวณจากผลรวมกำลังสองของความแตกต่างระหว่างข้อมูลแต่ละค่ากับค่าเฉลี่ยหารด้วยจำนวนข้อมูล โดยความแปรปรวนจะมีหน่วยยกกำลังสอง เช่น ความแปรปรวนของราคาหุ้นมีหน่วยเป็น บาท² หรือ ความแปรปรวนของน้ำหนัก มีหน่วยเป็น กิโลกรัม² เป็นต้น

$$\sigma^2 = \frac{\sum_{i=1}^N (X_i - \bar{X})^2}{N} \quad S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}$$

***การหารด้วย **n-1** เรียกว่า **Bessel's correction** ซึ่งช่วยให้การประมาณความแปรปรวนของประชากรจากข้อมูลตัวอย่างมีความเหมาะสมมากขึ้น

***เราสามารถเขียนสูตรความแปรปรวนในรูป Expectation ได้ด้วย

$$Var(X) = E[(X - \mu)^2] = E(X^2) - E[(\mu)^2]$$

3.4.4 ส่วนเบี่ยงเบนมาตรฐาน (Standard deviation)

เนื่องจากความแปรปรวนมีหน่วยเป็นยกกำลังสอง ซึ่งทำให้ยากต่อการทำความเข้าใจ ดังนั้น จึงใช้ค่าส่วนเบี่ยงเบนมาตรฐาน เพื่อให้ค่าการกระจายเป็นหน่วยเดียวกัน

$$\sigma = \sqrt{\sigma^2} \quad S = \sqrt{S^2}$$

ตัวอย่าง: นักลงทุนต้องการศึกษาความผันผวนของราคาหุ้นบริษัทแห่งหนึ่ง โดยเก็บข้อมูลราคาปิดของหุ้น (บาท) ในช่วง 5 วันทำการ ดังนี้

วัน	ราคาหุ้น	$x - \bar{x}$	$(x - \bar{x})^2$
1	98		
2	100		
3	102		
4	101		
5	99		

- ความแปรปรวนของตัวอย่าง (Sample Variance) พร้อมแปลความหมาย

- ส่วนเบี่ยงเบนมาตรฐานของตัวอย่าง (Sample Standard Deviation) พร้อมแปลความหมาย

3.4.5 ค่าสัมประสิทธิ์ของการกระจาย (Coefficient of Variation, C.V.)

ค่าสัมประสิทธิ์ของการกระจาย (Coefficient of Variation, C.V.) ใช้วัดการวัดการกระจายสัมพัทธ์ เมื่อต้องการเปรียบเทียบการกระจายข้อมูล 2 ชุดขึ้นไป ที่มีหน่วยเหมือนกันหรือแตกต่างกันก็ได้ โดยจะอธิบายเป็นร้อยละ

$$C.V. = \frac{S}{\mu} \times 100\%$$

ตัวอย่าง: ข้อมูลผลตอบแทนของกองทุน A, B, C จำนวนทั้งหมด 5 ปี มีดังนี้

กองทุน/ปี	1	2	3	4	5	Mean	s.d.	C.V.
A	7	5	7	10	4	6.6	2.06	
B	7	3	6	3	8	5.4	2.06	
C	10	3	7	3	10	6.6	3.14	

หากท่านเป็นนักลงทุน จะเลือกลงทุนในกองทุนใด เพราะเหตุใด ?

3.4.6 คะแนนมาตรฐาน (Z-score)

คะแนนมาตรฐาน (Z-score) คือ การหาว่าข้อมูลมีค่ามากกว่าหรือน้อยกว่าค่าเฉลี่ยเป็นกี่เท่าของส่วนเบี่ยงเบนมาตรฐาน ใช้เพื่อเปรียบเทียบข้อมูลประเภทเดียวกันแต่มีหน่วยแตกต่างกัน

$$Z = \frac{X - \mu}{\sigma}$$

ตัวอย่าง: นักศึกษาเศรษฐศาสตร์การจัดการและนักศึกษาเศรษฐศาสตร์ระหว่างประเทศ ใช้เวลาเฉลี่ยในการแก้ปัญหาคุณภาพตลาดเท่ากับ

นักศึกษา	ค่าเฉลี่ย	ค่าเบี่ยงเบนมาตรฐาน
เศรษฐศาสตร์การจัดการ	150 วินาที	30 วินาที
เศรษฐศาสตร์ระหว่างประเทศ	5 นาที	1 นาที

หากทำการสุ่มนักศึกษาเศรษฐศาสตร์การจัดการและนักศึกษาเศรษฐศาสตร์ระหว่างประเทศ ได้แก่ A, B พบว่าใช้เวลาในการแก้ปัญหาโจทย์เดียวกันเท่ากับ 170 วินาทีและ 6 นาที ตามลำดับ จงหาว่าใครแก้โจทย์ปัญหานี้ได้เร็วกว่ากัน

3.5 การนำเสนอข้อมูลด้วยกราฟ (Data Visualization)


การสร้างกราฟเป็นวิธีที่มีประสิทธิภาพในการนำเสนอข้อมูลอย่างชัดเจน

id	age	sex	smoker	income
1	19	female	yes	70
2	18	male	no	80
..	..	..	..	..
20	30	male	yes	98

	id	age	sex	smoker	income
count	20.000000	20.000000	20	20	20.000000
unique	NaN	NaN	2	2	NaN
top	NaN	NaN	male	no	NaN
freq	NaN	NaN	12	14	NaN
mean	10.500000	35.700000	NaN	NaN	79650.000000
std	5.91608	14.509888	NaN	NaN	18949.447985
min	1.000000	18.000000	NaN	NaN	45000.000000
25%	5.750000	24.500000	NaN	NaN	68750.000000
50%	10.500000	31.500000	NaN	NaN	79000.000000
75%	15.250000	47.500000	NaN	NaN	98000.000000
max	20.000000	62.000000	NaN	NaN	110000.000000


แผนภูมิแท่ง (Bar Chart)

- Bar Chart ใช้แถบเพื่อแสดงข้อมูลที่เป็นกลุ่มหรือหมวดหมู่ โดยแกน x แสดงกลุ่มข้อมูลและแกน y แสดงความถี่หรือค่าสถิติอื่นๆ เป็นกราฟแท่งที่ใช้แสดงข้อมูลเชิงปริมาณหรือเชิงคุณภาพ
- Example: สร้าง Bar Chart เพื่อเปรียบเทียบรายได้ของแต่ละบุคคล




แผนภูมิความถี่ (Histogram)

- Histogram แสดงการแจกแจงความถี่ของข้อมูลในรูปแบบของแท่งกราฟ โดยแกน x แสดงช่วงของข้อมูลและแกน y แสดงความถี่
- Example: สร้าง Histogram สำหรับข้อมูลรายได้




แผนภาพกล่อง (Box Plot)

- Box Plot แสดงการแจกแจงของข้อมูลโดยแสดงค่ากลาง ค่าควอไทล์ และค่าผิดปกติ (outliers)
- Example: สร้าง Box Plot สำหรับข้อมูลรายได้ผู้สูบบุหรี่และไม่สูบบุหรี่




แผนภาพการกระจาย (Scatter Plot)

- Scatter Plot แสดงความสัมพันธ์ระหว่างตัวแปรสองตัวโดยใช้จุดที่แสดงค่าของแต่ละตัวแปร เป็นกราฟที่แสดงความสัมพันธ์ระหว่างตัวแปรสองตัว
- Example: สร้าง Scatter Plot เพื่อแสดงความสัมพันธ์ระหว่างรายได้และอายุ



แผนภูมิวงกลม (Pie Chart)

- Pie Chart แสดงสัดส่วนหรือร้อยละของข้อมูลแต่ละหมวดหมู่เมื่อเทียบกับข้อมูลทั้งหมด โดยนำเสนอในรูปแบบวงกลมที่แบ่งออกเป็น ส่วน ๆ ตามสัดส่วนของแต่ละหมวดหมู่ เหมาะสำหรับการเปรียบเทียบองค์ประกอบของข้อมูลภายในชุดเดียวกัน
- Example: สร้างแผนภูมิวงกลม (Pie Chart) เพื่อแสดงสัดส่วนของยอดขายสินค้าแต่ละประเภทจากยอดขายทั้งหมด



3.6 ข้อจำกัดของการใช้สถิติพรรณนา

1. ไม่สามารถสรุปภาพรวมของประชากรได้อย่างชัดเจน

สถิติพรรณนาทำหน้าที่อธิบายชุดข้อมูลที่มีอยู่เท่านั้น (sample หรือ population เฉพาะชุด) แต่ไม่สามารถนำไปสรุปหรืออนุมานถึงประชากร (population inference) ได้โดยตรง ตัวอย่างเช่น ค่าเฉลี่ยของกลุ่มตัวอย่างอาจไม่สะท้อนค่ากลางของประชากรทั้งหมด

2. ไม่สามารถวัดความไม่แน่นอนหรือความเชื่อมั่นของข้อมูล

ไม่มีการให้ข้อมูลเกี่ยวกับ ความน่าจะเป็น (probability) หรือ ช่วงความเชื่อมั่น (confidence interval) ทำให้ไม่สามารถวิเคราะห์ความเสี่ยงหรือระดับความเชื่อมั่นในการตัดสินใจได้ เช่น การตัดสินใจเชิงนโยบายไม่ควรใช้เพียงค่าเฉลี่ยหรือค่ากลางโดยไม่มีการวิเคราะห์ความไม่แน่นอนร่วมด้วย

3. ไม่สามารถทดสอบสมมติฐานหรือความสัมพันธ์ระหว่างตัวแปร

สถิติพรรณนาไม่สามารถตอบคำถามเชิงสาเหตุ (causality) หรือทดสอบทางสถิติได้ เช่น “รายได้กับการศึกษาเกี่ยวข้องกันหรือไม่?” หรือ “นโยบายกระตุ้นเศรษฐกิจส่งผลต่อการบริโภคหรือไม่?”

4. อาจบิดเบือนความจริงได้ หากตีความไม่ระมัดระวัง

สถิติบางตัว เช่น ค่าเฉลี่ย อาจได้รับอิทธิพลจากค่าผิดปกติ (outliers) ตัวอย่างเช่น ค่าเฉลี่ยรายได้ในประเทศที่มีช่องว่างรายได้สูง อาจดูสูงเกินจริง และไม่สะท้อนรายได้ของคนส่วนใหญ่

5. ไม่สามารถคาดการณ์อนาคตได้

สถิติพรรณนาใช้กับข้อมูลในอดีตหรือปัจจุบันเท่านั้น จึงไม่สามารถใช้ในการพยากรณ์ (forecasting) หรือจำลองสถานการณ์อนาคต